Clasificación de Residuos Sólidos en Siete Clases mediante Redes Neuronales Convolucionales y Aprendizaje por Transferencia para un Tacho Inteligente

1er Echegoyen Rojas Anahi
Facultad de Ingeniería de Sistemas
Universidad Nacional del Centro del Perú
Huancayo, Perú
e_2024200183A@uncp.edu.pe

2do Espinoza Inga Deysi
Facultad de Ingeniería de Sistemas
Universidad Nacional del Centro del Perú
Huancayo, Perú
e_2024200184B@uncp.edu.pe

3er Paucar Ramirez Carolina
Facultad de Ingeniería de Sistemas
Universidad Nacional del Centro del Perú
Huancayo, Perú
e_2024200196A@uncp.edu.pe

4to Tomas Rivera Andriy
Facultad de Ingeniería de Sistemas
Universidad Nacional del Centro del Perú
Huancayo, Perú
e_2024200206K@uncp.edu.pe

***Resumen*—La separación en la fuente de los residuos sólidos es un paso clave para su aprovechamiento, pero suele fallar por errores humanos. Este trabajo presenta un sistema de clasificación automática de imágenes de residuos en siete clases (metal, orgánico, papel y cartón, peligroso, plástico, vidrio y otros), concebido como base de un tacho inteligente. Se construyó un conjunto de datos unificado de 29 212 imágenes a partir de cuatro fuentes, dos de objetos aislados (Roboflow) y dos de residuos en condiciones reales (RealWaste y TACO), con eliminación de duplicados mediante hash perceptual para evitar fugas de datos entre particiones. Se compararon tres modelos: una red convolucional residual entrenada desde cero, MobileNetV2 con el extractor de características congelado y MobileNetV2 con ajuste fino parcial en dos fases. En el conjunto de prueba, el ajuste fino obtuvo la mejor exactitud (89.3 %) y la mejor medida F1 macro (0.870), frente a 77.1 % y 0.720 de la red propia. Sin embargo, la exactitud sobre imágenes de TACO fue de solo 59.1 %, lo que evidencia una brecha importante entre imágenes de estudio y residuos reales. El modelo seleccionado se convirtió a TensorFlow Lite con precisión de 16 bits, con un tamaño de 4.6 MB, y se integró en una aplicación de demostración con umbral de confianza.**

***Index Terms*—clasificación de residuos, redes neuronales convolucionales, aprendizaje por transferencia, MobileNetV2, ajuste fino, tacho inteligente**

I. Introducción

El manejo inadecuado de los residuos sólidos urbanos es un problema ambiental y de salud pública. La segregación en el punto de origen permite reciclar y tratar cada tipo de residuo de forma adecuada, pero depende de que las personas identifiquen correctamente en qué contenedor debe ir cada objeto. La visión por computador ofrece una alternativa: un tacho equipado con una cámara podría reconocer el residuo y sugerir el contenedor correspondiente.

Los trabajos de clasificación de residuos con aprendizaje profundo suelen reportar altas exactitudes sobre imágenes tomadas en condiciones controladas, es decir, un objeto centrado sobre un fondo uniforme. En un uso real, en cambio, los objetos aparecen sucios, deformados, parcialmente ocultos y con iluminación variable. Por ello, el reto principal de este trabajo no es solo alcanzar una exactitud alta, sino medir cuánto se degrada el rendimiento al pasar de fotos de estudio a residuos en condiciones reales.

Las contribuciones de este informe son las siguientes:

- Un conjunto de datos unificado de siete clases construido a partir de cuatro fuentes, con asignación explícita de clases, división sin fugas de datos y limpieza por hash perceptual.
- Una comparación controlada de tres estrategias de entrenamiento (red desde cero, extracción de características y ajuste fino parcial) bajo la misma partición, el mismo aumento de datos y los mismos criterios de parada.
- Una evaluación desagregada por origen de las imágenes, que cuantifica la brecha entre fotos de estudio y residuos reales, y un análisis de errores.
- La conversión del mejor modelo a un formato liviano y su integración en una aplicación de demostración.

El resto del documento se organiza así: la Sección II resume los fundamentos; la Sección III describe los datos; la Sección IV presenta los modelos y el entrenamiento; la Sección V expone los resultados; la Sección VI los discute; la Sección VII describe el despliegue y la Sección VIII concluye.

II. Fundamentos

II-A. Redes residuales y MobileNetV2

Las conexiones residuales permiten entrenar redes más profundas al sumar la entrada de un bloque a su salida, lo que facilita la propagación del gradiente [4]. MobileNetV2 emplea bloques residuales invertidos con convoluciones separables en profundidad, lo que reduce de forma notable el número de parámetros y el costo de cómputo, y por eso es adecuada para dispositivos con recursos limitados [3].

II-B. Aprendizaje por transferencia

Las características aprendidas en un conjunto grande como ImageNet [5] son reutilizables en otras tareas de visión, sobre todo las de las primeras capas, que son más generales [6]. Existen dos estrategias habituales: *extracción de características*, en la que el extractor preentrenado se congela y solo se entrena un nuevo clasificador, y *ajuste fino*, en la que además se reentrenan las últimas capas del extractor con una tasa de aprendizaje baja.

II-C. Métricas

Dado que las clases están desbalanceadas, la métrica principal es la medida F1 macro, que promedia el F1 de las C clases con el mismo peso:

$$\mathrm{F1}_{\mathrm{macro}} = \frac{1}{C} \sum_{c=1}^{C} \frac{2\, P_c\, R_c}{P_c + R_c}, \tag{1}$$

donde P_c y R_c son la precisión y la exhaustividad de la clase c. La exactitud se reporta como referencia.

III. Datos y preprocesamiento

III-A. Fuentes de datos

Se emplearon cuatro fuentes, resumidas en la Tabla I. Las dos primeras son conjuntos de Roboflow Universe: *Garbage-Classification* (versión 6), con 13 clases de objetos aislados, y *Waste-Classification* (versión 3), con gran cantidad de residuo orgánico, bolsas y botellas. La tercera es RealWaste [1], con 4 752 fotografías en nueve clases tomadas en un vertedero, con residuos sucios y mezclados. La cuarta es TACO [2], con 1 500 fotografías de basura en calles, bosques y playas anotadas con cajas delimitadoras; en este trabajo se recortó cada objeto anotado con un margen de contexto del 10 %, se descartaron los recortes menores de 40 píxeles de ancho o de alto (908 recortes) y se obtuvieron 3 869 recortes útiles.

III-B. Unificación de clases

Las clases originales de cada fuente se asignaron a siete clases finales: `metal`, `organico`, `otros`, `papel_carton`, `peligroso`, `plastico` y `vidrio`. Cada clase se asocia a un contenedor sugerido (por ejemplo, el contenedor amarillo para metales y el rojo para residuos peligrosos). Las clases sin equivalencia clara se descartaron en lugar de forzarlas: la clase mixta *cardboard plastic* de ds1 y los residuos de madera (*wood_waste*) de ds2. Las categorías de TACO, que son cerca de 60, se asignaron mediante reglas por palabras clave; los envases mixtos (*blister*) se descartaron. Esta asignación es una decisión de diseño que introduce cierto ruido de etiquetas, por ejemplo en botellas, cuyo material depende de la clase de TACO.

Cuadro I
Imágenes por origen y partición

Origen	Inicial[a]	Entren.	Valid.	Prueba
Garbage-Class. (ds1)	21 605	8 733	1 341	1 356
Waste-Class. (ds2)	24 465	4 855	2 862	1 444
RealWaste (rw)	4 752	3 329	713	710
TACO (taco)	3 869	2 761	556	552
Total	54 691	19 678	5 472	4 062

[a]Tras asignar clases y antes de eliminar duplicados y limitar el conjunto de entrenamiento.

Cuadro II
Imágenes por clase y partición

Clase	Entren.	Valid.	Prueba	Total
`metal`	2 953	414	365	3 732
`organico`	3 000	2 552	1 404	6 956
`otros`	3 000	931	903	4 834
`papel_carton`	3 000	505	478	3 983
`peligroso`	1 725	123	114	1 962
`plastico`	3 000	629	539	4 168
`vidrio`	3 000	318	259	3 577
Total	19 678	5 472	4 062	29 212

III-C. Particiones y control de fugas

Se respetaron las particiones originales de Roboflow, cuyo aumento de datos está solo en entrenamiento. RealWaste, que no trae particiones, se dividió 70/15/15 por clase. TACO se dividió 70/15/15 *por fotografía original*, de modo que dos recortes de una misma foto nunca queden en particiones distintas. Se calculó un hash perceptual de diferencias (dHash) de 256 bits para cada imagen, que detecta copias redimensionadas o recomprimidas. Se eliminaron 23 imágenes de entrenamiento presentes en validación o prueba y 65 duplicados internos; no se encontraron imágenes corruptas.

Para controlar el desbalance, se limitó el entrenamiento a 3 000 imágenes por clase, conservando primero las de RealWaste y TACO. La validación y la prueba no se limitaron. El resultado se muestra en la Tabla II y la Fig. 1. La razón de desbalance en entrenamiento es de 1.7:1, pero en prueba la clase orgánica representa el 34.6 % de las imágenes (1 404 de 4 062), por lo que la exactitud por sí sola sobrestima el desempeño y se prioriza F1 macro.

Debe notarse que la composición por origen es desigual entre clases. En entrenamiento, `peligroso` proviene casi por completo de objetos aislados (1 389 de ds1 y 334 de ds2, con solo 2 de TACO y ninguna de RealWaste), `vidrio` no tiene imágenes de ds2 y `organico` tiene solo 8 recortes de TACO.

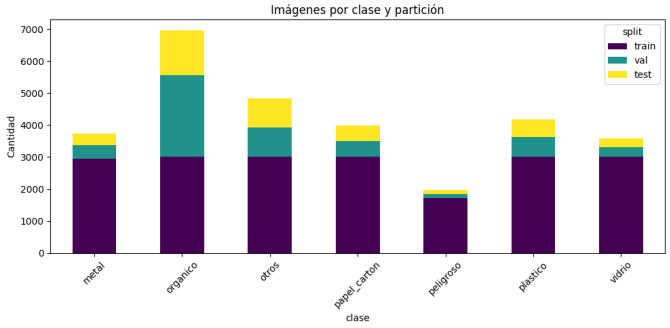


Figura 1. Imágenes por clase y partición del conjunto unificado.

III-D. *Preprocesamiento y aumento de datos*

Las imágenes se leen por lotes desde disco y se recortan al cuadrado central y se redimensionan a 224×224 píxeles sin deformar el objeto; la aplicación aplica el mismo recorte al predecir. El aumento de datos forma parte del modelo y solo se activa durante el entrenamiento: volteo horizontal, rotación (hasta 8 % de vuelta), traslación ($\pm 8\,\%$), zoom (de $-20\,\%$ a $+10\,\%$), contraste ($\pm 20\,\%$) y brillo ($\pm 20\,\%$).

IV. Modelos y entrenamiento

IV-A. *Modelo 1: red convolucional residual propia*

Se diseñó una red desde cero con una convolución inicial de 7×7 con paso 2 y *max pooling*, seguida de cuatro bloques residuales (32, 64, 128 y 256 filtros, cada uno con dos convoluciones 3×3 y normalización por lotes), promedio global, *dropout* de 0.4, una capa densa de 128 unidades con regularización L2 (10^{-4}), *dropout* de 0.3 y la capa de salida softmax. Tiene 1 266 919 parámetros.

IV-B. *Modelo 2: MobileNetV2 con extractor congelado*

Se usó MobileNetV2 preentrenada en ImageNet sin su capa final, con el extractor completamente congelado. Sobre él se añadieron promedio global, normalización por lotes, *dropout* de 0.3, una capa densa de 128 unidades, *dropout* de 0.2 y la capa softmax. El modelo tiene 2 427 975 parámetros, de los cuales solo 167 431 (6.9 %) son entrenables. La normalización por lotes del extractor se mantiene en modo de inferencia.

IV-C. *Modelo 3: MobileNetV2 con ajuste fino parcial*

Tiene la misma arquitectura que el modelo 2 y se entrena en dos fases. En la fase 1 (calentamiento) se entrena solo el clasificador con el extractor congelado y tasa de aprendizaje 10^{-3}. En la fase 2 se descongelan las últimas 40 de las 154 capas del extractor (114 permanecen congeladas), lo que eleva los parámetros entrenables a 1 848 967, y se recompila con tasa de aprendizaje 10^{-5}, es decir 100 veces menor.

IV-D. *Configuración común*

Los tres modelos usan el optimizador Adam [7], tamaño de lote 32 y entropía cruzada categórica con suavizado de etiquetas de 0.05 [8]. Los pesos de clase siguen la fórmula *balanced*:

$$w_c = \frac{N}{C\, n_c}, \tag{2}$$

donde N es el total de imágenes de entrenamiento, $C = 7$ y n_c el número de imágenes de la clase c; la única clase con peso distinto de $\approx$0.95 es `peligroso` (1.63). Se emplearon *ModelCheckpoint*, *EarlyStopping* con restauración de los mejores pesos y *ReduceLROnPlateau* (factor 0.5), los tres sobre la pérdida de validación. Se fijó la semilla 42 y se usó TensorFlow [9] en Google Colab con GPU. Las épocas máximas fueron 40 (red propia), 15 (extracción de características) y 6 más 20 (ajuste fino, fases 1 y 2).

Cuadro III
Resultados globales en el conjunto de prueba

Modelo	Exact.	F1 macro	Prec. macro	Exh. macro	Tiempo (min)
CNN propia	0.771	0.720	0.719	0.729	34.5
MobileNetV2 FE	0.888	0.860	0.862	0.860	15.0
MobileNetV2 FT	**0.893**	**0.870**	**0.869**	**0.872**	23.0

FE: extracción de características; FT: ajuste fino parcial.

V. Resultados

V-A. *Entrenamiento*

La red propia convergió lentamente y con una validación inestable: se detuvo en la época 37 y restauró los pesos de la época 29, con exactitud de validación de 0.803 y pérdida de 0.784; tardó 34.5 minutos. La extracción de características alcanzó 0.911 de exactitud de validación al completar las 15 épocas (pérdida 0.516) en 15.0 minutos, sin activar la parada temprana. En el ajuste fino, la fase 1 restauró los pesos de la época 5 (validación 0.904); al iniciar la fase 2 la exactitud de validación bajó brevemente (de 0.904 a 0.893) y luego subió de forma sostenida hasta 0.916 en la época 20 (pérdida 0.496), sin que se activara la parada temprana. El tiempo total fue de 23.0 minutos. La Fig. 2 muestra las curvas de la red propia y del ajuste fino.

En ambos modelos preentrenados la exactitud de entrenamiento es menor que la de validación. Esto es esperable: durante el entrenamiento están activos el aumento de datos, el *dropout* y el suavizado de etiquetas, y además la validación contiene un 46.6 % de imágenes orgánicas, la clase más fácil. No se observa sobreajuste; en el ajuste fino la brecha se cierra y la validación seguía mejorando al terminar, lo que sugiere que más épocas podrían aportar una mejora adicional.

V-B. *Resultados en el conjunto de prueba*

La Tabla III compara los tres modelos sobre el conjunto de prueba (4 062 imágenes), que ningún modelo vio durante el entrenamiento ni la selección de pesos. Como referencia, un clasificador aleatorio logra 14.3 % y uno que siempre predice la clase mayoritaria logra 34.6 % en prueba (15.2 % en entrenamiento).

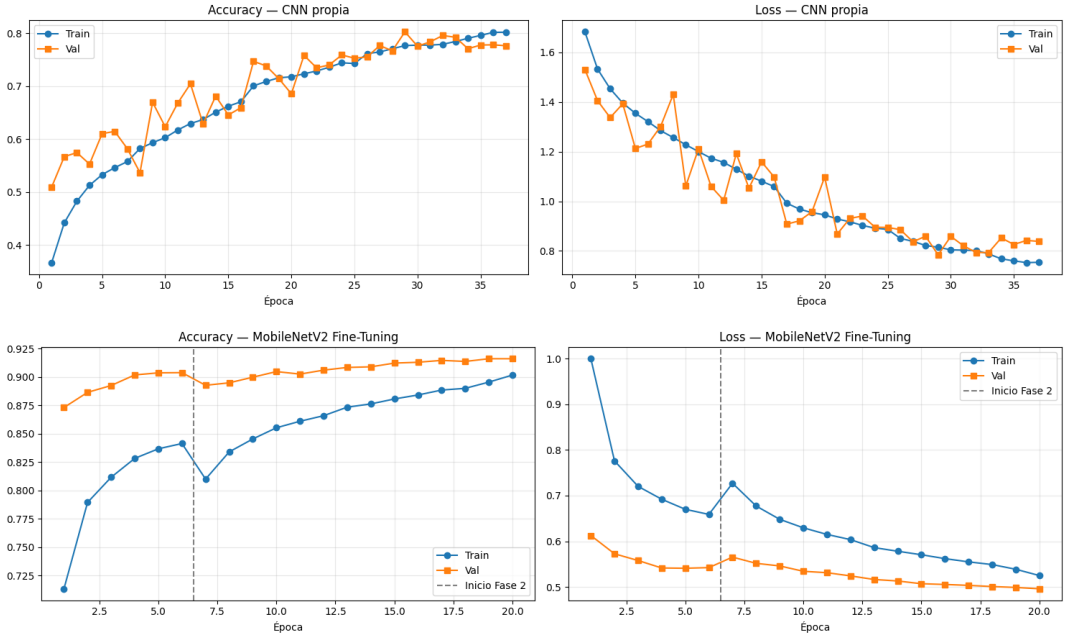


Figura 2. Curvas de exactitud y pérdida: red propia (arriba) y MobileNetV2 con ajuste fino (abajo). La línea discontinua marca el inicio de la fase 2.

Cuadro IV
EXACTITUD EN PRUEBA POR ORIGEN DE LAS IMÁGENES

Modelo	ds1 (n=1 356)	ds2 (1 444)	rw (710)	taco (552)
CNN propia	0.770	0.904	0.758	0.442
MobileNetV2 FE	0.946	**0.979**	0.823	**0.592**
MobileNetV2 FT	**0.954**	0.970	**0.855**	0.591

Los modelos preentrenados superan a la red propia por una amplia diferencia: con ajuste fino, +12.2 puntos porcentuales (pp) en exactitud y +15.0 pp en F1 macro, y además entrenan en menos tiempo. El ajuste fino supera a la extracción de características por solo 0.5 pp en exactitud y 1.0 pp en F1 macro. Con 4 062 imágenes, el error estándar binomial de la exactitud es cercano a 0.5 pp, por lo que esta diferencia es del mismo orden que la incertidumbre de muestreo; además se entrenó una sola vez cada modelo y no se aplicó una prueba de significancia, por lo que no puede afirmarse que el ajuste fino sea mejor que la extracción de características solo con estos datos.

V-C. Rendimiento por origen

La Tabla IV desagrega la exactitud según el origen de las imágenes de prueba. Todos los modelos rinden mejor en las fuentes de objetos aislados (ds1 y ds2) que en las de residuos reales (rw y taco). Para el modelo de ajuste fino, la exactitud cae de 95.4 % en ds1 a 85.5 % en RealWaste (9.9 pp) y a 59.1 % en TACO (36.3 pp). El ajuste fino mejora a la extracción de características en RealWaste (+3.2 pp, cerca de dos errores estándar con $n = 710$) pero no en TACO (59.1 % frente a 59.2 %).

Cuadro V
F1 POR CLASE EN EL CONJUNTO DE PRUEBA

Clase	CNN propia	FE	FT
`metal`	0.618	**0.797**	0.791
`organico`	0.914	**0.979**	0.977
`otros`	0.745	0.905	**0.911**
`papel_carton`	0.734	**0.869**	0.867
`peligroso`	0.679	0.944	**0.952**
`plastico`	0.621	0.744	**0.761**
`vidrio`	0.727	0.784	**0.830**

V-D. Rendimiento por clase y errores

La Tabla V presenta el F1 por clase. Las clases `organico` (0.977) y `peligroso` (0.952) son las mejor resueltas por el modelo de ajuste fino; las más difíciles son `plastico` (0.761) y `metal` (0.791). El ajuste fino mejora sobre la extracción de características sobre todo en `vidrio` (+4.6 pp de F1) y en `plastico` (+1.6 pp), y queda ligeramente por debajo en `metal` (-0.6 pp).

El modelo de ajuste fino cometió 435 errores en 4 062 imágenes (10.7 %). La Fig. 3 muestra su matriz de confusión y la Tabla VI las confusiones más frecuentes. La clase `plastico` aparece en seis de las ocho: es la clase de destino de los errores de `metal` y `otros`, y a su vez se confunde con `papel_carton`, `vidrio` y `metal`. De las imágenes de metal, el 17.3 % se clasificó como plástico.

El examen visual de una muestra aleatoria de errores (Fig. 4) muestra patrones recurrentes: recortes de TACO borrosos, de baja resolución o con el objeto parcialmente visible; objetos cuyo material es ambiguo a simple vista (una botella plástica verdosa que se asemeja al vidrio, papel de aluminio envolvien-

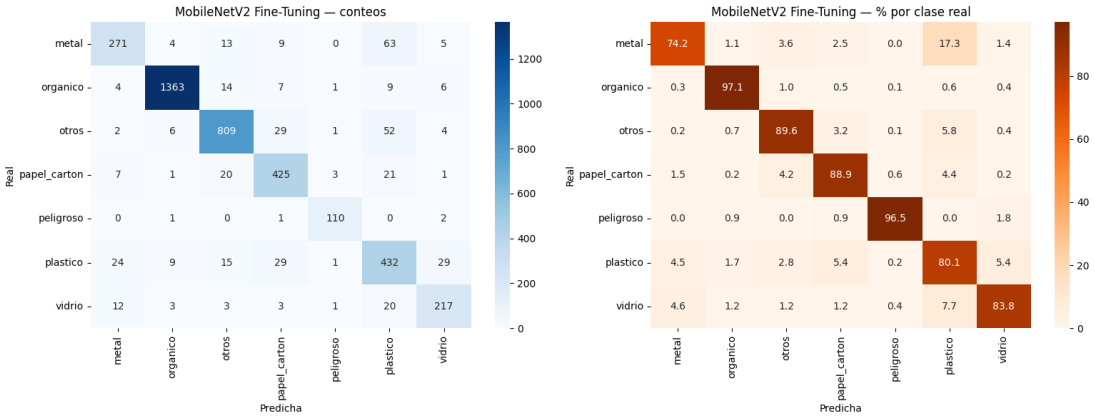


Figura 3. Matriz de confusión de MobileNetV2 con ajuste fino en el conjunto de prueba: conteos (izquierda) y porcentaje por clase real (derecha).

Cuadro VI
PRINCIPALES CONFUSIONES DEL MODELO CON AJUSTE FINO

Real	Predicha	Errores
metal	plastico	63
otros	plastico	52
otros	papel_carton	29
plastico	papel_carton	29
plastico	vidrio	29
plastico	metal	24
papel_carton	plastico	21
papel_carton	otros	20

do comida); y envases que combinan materiales. En muchos de estos casos la confianza del modelo es moderada (entre 36 % y 87 % en la muestra), lo que indica que un umbral de confianza puede filtrar parte de ellos.

VI. Discusión

VI-A. *Comparación de estrategias*

La ventaja del aprendizaje por transferencia es clara y consistente: los dos modelos preentrenados superan a la red propia en todas las clases y en todos los orígenes, con una brecha mayor justamente en los datos más difíciles (en TACO, 59 % frente a 44 %). Una explicación plausible es que las características generales de ImageNet, como bordes, texturas y formas, son más robustas ante fondos desordenados que las aprendidas por una red pequeña con unas 20 000 imágenes. Esta explicación es una hipótesis y no se probó con un experimento de ablación.

El ajuste fino aporta una mejora pequeña frente a la extracción de características, con un costo de entrenamiento mayor (23.0 frente a 15.0 minutos). Las mejoras se concentran en RealWaste (+3.2 pp) y en la clase `vidrio`, lo que es coherente con la idea de que reentrenar las capas altas adapta las características a la apariencia de residuos reales, pero no se observa mejora en TACO. Dado que la validación seguía mejorando al terminar la fase 2, una exploración del número de capas descongeladas (20, 40, 60) y de más épocas es una continuación natural.

VI-B. *Brecha entre fotos de estudio y residuos reales*

El resultado más importante para el uso previsto es que la exactitud global de 89.3 % oculta una gran heterogeneidad: 95–97 % en objetos aislados, 85.5 % en un vertedero real y 59.1 % en residuos fotografiados en exteriores. Esto confirma la motivación del trabajo: un modelo evaluado únicamente con ds1 y ds2 parecería mucho mejor de lo que es. Además, el conjunto de prueba está dominado por imágenes de objetos aislados (69 % provienen de ds1 y ds2), de modo que el desempeño esperado en un contexto de uso real, con mayor proporción de imágenes difíciles, sería inferior a la cifra global.

Se identifican varias causas posibles del bajo desempeño en TACO, que deberían verificarse: la baja resolución de muchos recortes, que se reducen a 224×224; la pérdida del contexto al recortar el objeto; la heurística de asignación de clases, que genera ruido en las etiquetas; y la escasa representación de TACO en algunas clases de entrenamiento. Para la clase `peligroso`, el excelente F1 (0.952) debe interpretarse con cautela: sus imágenes de entrenamiento y de prueba son casi todas de objetos aislados, de modo que ese resultado probablemente no se mantendría con baterías o residuos electrónicos en escenas reales.

VI-C. *Tabla de mejoras*

La Tabla VII relaciona los hallazgos de errores con posibles causas y acciones correctivas. Las causas son hipótesis basadas en la inspección de la matriz de confusión y de ejemplos, y no han sido validadas.

VI-D. *Limitaciones*

Los resultados deben leerse con las siguientes salvedades. Cada modelo se entrenó una sola vez con una semilla, por lo que no se midió la variabilidad entre ejecuciones. No se aplicó una prueba estadística a las diferencias entre modelos. La asignación de clases de TACO por palabras clave y la agrupación de categorías heterogéneas en `otros` introducen



Figura 4. Muestra aleatoria de diez errores del modelo de ajuste fino. Cada título indica el origen, la clase real, la clase predicha y la confianza.

Cuadro VII
HALLAZGOS DEL ANÁLISIS DE ERRORES Y ACCIONES CORRECTIVAS PROPUESTAS

Hallazgo	Posible causa	Acción propuesta
`metal→plastico` (63 errores; 17.3 % del metal)	Latas y envolturas metalizadas con brillo y reflejos similares al plástico; reglas de TACO que asignan papel de aluminio a metal y envolturas a plástico.	Revisar la asignación de clases de TACO; agregar imágenes reales de metal; aumentar la resolución de entrada; evaluar más capas descongeladas.
`otros→plastico` (52) y `otros→papel_carton` (29)	La clase `otros` es heterogénea (espuma, textiles, papel plastificado, residuos varios) y su frontera con plástico y papel es difusa.	Redefinir o subdividir `otros`; añadir un umbral de rechazo para casos de baja confianza.
`plastico↔vidrio` / `metal` / `papel_carton` (29, 24, 29)	Los plásticos son visualmente muy variados (botellas transparentes o de color, bolsas, películas) y comparten forma con envases de otros materiales.	Aumentar ejemplos reales de plástico transparente y de color; aumento de datos específico (color y brillo); aumento en tiempo de prueba.
Bajo desempeño en TACO (59.1 % de exactitud)	Recortes pequeños y borrosos, objetos parciales, pérdida de contexto y ruido en las etiquetas.	Filtrar recortes por calidad y resolución mínima; ampliar el margen de contexto; recolectar fotos propias con la cámara del tacho.

ruido de etiquetas. Las particiones de validación y prueba conservan la distribución original de las fuentes y están dominadas por la clase orgánica. Finalmente, no se midieron la latencia de inferencia en un dispositivo real ni la pérdida de exactitud por la conversión a TensorFlow Lite.

VII. DESPLIEGUE

El modelo seleccionado para producción es MobileNetV2 con ajuste fino, por tener el mayor F1 macro. El archivo en formato Keras pesa 24.0 MB, pero la conversión a TensorFlow Lite lo reduce a 9.1 MB en precisión de 32 bits y a 4.6 MB con cuantización a 16 bits, lo que cumple la restricción de menos de 10 MB planteada para una aplicación móvil. Junto con el modelo se guarda un archivo de metadatos con las clases, el tamaño de entrada, el preprocesamiento, los conjuntos de datos usados, las métricas y las versiones del entorno.

La función de predicción recibe una imagen, recorta el cuadrado central, la redimensiona y devuelve la clase, la confianza, las tres clases más probables y el contenedor sugerido. Se desarrolló una demostración con Gradio y una aplicación de escritorio con cámara en vivo, que solicitan una nueva foto cuando la confianza es menor de 0.60. Este umbral se fijó de manera heurística y no se evaluó cuantitativamente su efecto sobre la cobertura y la exactitud.

VIII. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo construyó un conjunto unificado de 29 212 imágenes de siete clases a partir de cuatro fuentes, sin fugas de datos entre particiones, y comparó tres estrategias de entrenamiento para clasificar residuos sólidos. Las conclusiones principales son las siguientes.

1. **El aprendizaje por transferencia es claramente superior a entrenar desde cero.** MobileNetV2 preentrenada alcanzó 88.8 % (extracción de características) y 89.3 % (ajuste fino) de exactitud en prueba, frente a 77.1 % de

la red propia, con F1 macro de 0.860 y 0.870 frente a 0.720, y con un tiempo de entrenamiento menor.

2. **El ajuste fino ofrece una ventaja pequeña.** Mejora a la extracción de características en 0.5 pp de exactitud y 1.0 pp de F1 macro, una diferencia comparable con la incertidumbre de muestreo; su beneficio más visible está en RealWaste (+3.2 pp) y en la clase vidrio. Se lo eligió para producción por obtener el mejor F1 macro, no porque su superioridad esté demostrada estadísticamente.
3. **Existe una brecha importante entre objetos aislados y residuos reales.** La exactitud del modelo elegido es de 95.4 % en ds1 y 97.0 % en ds2, pero de 85.5 % en RealWaste y de solo 59.1 % en TACO. Un tacho inteligente que opere en condiciones reales debe esperar un desempeño inferior al global de 89.3 %.
4. **Los errores se concentran en materiales visualmente similares.** Las confusiones principales involucran a la clase plástico (metal→plástico, otros→plástico, plástico↔vidrio), debido a la variedad visual de los plásticos, la ambigüedad de la clase `otros` y la calidad de los recortes de TACO.
5. **El modelo es viable para dispositivos con recursos limitados.** La versión de TensorFlow Lite con cuantización a 16 bits pesa 4.6 MB, y se integró en una aplicación de demostración con umbral de confianza.

Trabajo futuro. Se proponen: (i) recolectar y etiquetar imágenes propias tomadas con la cámara del tacho en condiciones reales, que es la acción con mayor impacto esperado; (ii) depurar la asignación de clases de TACO y filtrar recortes de baja calidad; (iii) explorar el número de capas descongeladas y entrenar por más épocas; (iv) repetir los experimentos con varias semillas y aplicar pruebas de significancia; (v) medir la latencia y la exactitud del modelo cuantizado en un dispositivo real; y (vi) calibrar el umbral de confianza analizando la relación entre cobertura y exactitud.

AGRADECIMIENTOS

Los autores agradecen a los creadores de los conjuntos de datos RealWaste y TACO, y a los autores de los conjuntos de Roboflow Universe. Este trabajo se realizó en el curso IS056B Ingeniería del Conocimiento, de la Universidad Nacional del Centro del Perú, periodo 2026-II.

REFERENCIAS

[1] S. Single, S. Iranmanesh and R. Raad, "RealWaste," UCI Machine Learning Repository, 2023, doi:10.24432/C5SS4G (licencia CC BY 4.0).

[2] P. F. Proença and P. Simões, "TACO: Trash annotations in context for litter detection," arXiv:2003.06975, 2020.

[3] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov and L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510–4520.

[4] K. He, X. Zhang, S. Ren and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[5] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li and L. Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2009, pp. 248–255.

[6] J. Yosinski, J. Clune, Y. Bengio and H. Lipson, "How transferable are features in deep neural networks?," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 27, 2014.

[7] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2015.

[8] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens and Z. Wojna, "Rethinking the Inception architecture for computer vision," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 2818–2826.

[9] M. Abadi *et al.*, "TensorFlow: A system for large-scale machine learning," in *Proc. USENIX Symp. Operating Systems Design and Implementation (OSDI)*, 2016, pp. 265–283.